CBE
ENGENHARIA E CONSTRUÇÃO EM TELECOMUNICAÇÕES

Nome Silva
e
Rodrigo Bezerra

① a) Classe N: x_1, x_2, x_4

Classe P: x_3, x_5, x_6

$P(y_6 = N) = P(y_6 = P) = 0,5$ Sabendo que $\begin{bmatrix} y_1 \\ y_2 \end{bmatrix} \sim N(\mu_k, M, \Sigma)$:

Classe N:

$$\mu_N = \frac{1}{3}\left(\begin{bmatrix} 0,54 \\ 0,74 \end{bmatrix} + \begin{bmatrix} 0,49 \\ 0,58 \end{bmatrix} + \begin{bmatrix} 0,42 \\ 0,46 \end{bmatrix}\right) = \begin{bmatrix} \frac{1,45}{3} \\ \frac{2,18}{3} \end{bmatrix} \simeq \begin{bmatrix} 0,4833 \\ 0,7267 \end{bmatrix}$$

Restam:

$x_1 - \mu_N \simeq [0,0567, 0,0133]^T$

$x_2 - \mu_N \simeq [0,0067, 0,1533]^T$

$x_4 - \mu_N \simeq [-0,0633, -0,1667]^T$ $n-1=2$

$$\Sigma_N = \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix} \simeq \begin{bmatrix} 0,00363 & 0,00967 \\ 0,00967 & 0,06773 \end{bmatrix}$$

Classe P: $\mu_P = \frac{1}{3}\left(\begin{bmatrix} 0,49 \\ 0,56 \end{bmatrix} + \begin{bmatrix} 0,63 \\ 0,33 \end{bmatrix} + \begin{bmatrix} 0,50 \\ 0,46 \end{bmatrix}\right) = \begin{bmatrix} \frac{1,62}{3} \\ \frac{1,35}{3} \end{bmatrix} \simeq \begin{bmatrix} 0,5562 \\ 0,45 \end{bmatrix}$

Restam:

$x_3 - \mu_P \simeq [-0,0667, 0,1100]^T$

$x_5 - \mu_P \simeq [0,1233, -0,12]$

$x_6 - \mu_P \simeq [-0,0567, 0,01]$

$$\Sigma_P = \begin{bmatrix} 0,01193 & -0,01135 \\ -0,01135 & 0,01330 \end{bmatrix}$$

$\det \Sigma_N \simeq 1,526 \times 10^{-7}$ $\quad \det \Sigma_P = 2,329 \times 10^{-5}$

Para y_3 → Bernoulli

Classe N: $P(y_3=1|N) = \frac{2}{3}$ $P(y_3=0|N) = \frac{1}{3}$

Classe P: $P(y_3=1|P) = 1$ $P(y_3=0|P) = 0$

Para y_4, y_5, como eles são independentes entre si, modela-se a probabilidade conjunta dos pares (y_4, y_5):

Classe N:

~~$P(0,0|N)$~~ $P(0,0|N) = \frac{2}{3}$ $P(1,0|N) = \frac{1}{3}$

$P(0,1|N) = 0$ $P(1,1|N) = 0$

Classe P:

$P(1,0|P) = \frac{2}{3}$ $P(1,1|P) = \frac{1}{3}$ $P(0,0|P) = 0$ $P(0,1|P) = 0$

Algumas estimativas:

para N: $\sigma^2_{1,N} = \frac{0,0567^2 + 0,0067^2 + (-0,0633)^2}{2} = \frac{0,007347}{2} \simeq 0,003673$

$\sigma^2_{2,N} = \frac{0,0133^2 + 0,2533^2 + (-0,2667)^2}{2} = \frac{0,134756}{2} \simeq 0,067378$

$\sigma_{12,N} = \frac{(0,0767)(0,0133) + (0,0067)(0,2533) + (-0,0633)(-0,2667)}{2} \simeq 0,00967$

Classe P:

$\sigma^2_{1,P} = \frac{(-0,0667)^2 + 0,1133^2 + (-0,0567)^2}{2} = \frac{0,021867}{2} \simeq 0,010933$

$\sigma^2_{2,P} = \frac{0,11^2 + (-0,11)^2 + 0,01^2}{2} = \frac{0,0266}{2} = 0,0133$

$\sigma_{12,P} = \frac{(-0,0667)(0,11) + (0,1133)(-0,11) + (-0,0567)(0,01)}{2} = -\frac{0,01227}{2}$

$\simeq -0,006135$

b) Segundo o critério MAP escolhemos a classe que maximiza a probabilidade a posteriori

$$\hat{y} = \arg\max_{c \in \{P,N\}} P(y_6 = c) \cdot p(y_1, y_2 | c) \cdot p(y_3 | c) \cdot p(y_4, y_5 | c)$$

Pode-se escrever $p(y_1, y_2 | c) = \frac{1}{2\pi \sqrt{\det \Sigma_c}} e^{-\frac{1}{2}(y_{12} - \mu_c)^T \Sigma_c^{-1} (y_{12} - \mu_c)}$

$$\Sigma_N^{-1} = \frac{1}{(5,26 \times 10^{-7}} \begin{pmatrix} 0,06273 & -0,00967 \\ -0,00967 & 0,00363 \end{pmatrix} \simeq \begin{pmatrix} 423,8 & -63,3 \\ -63,3 & 23,8 \end{pmatrix}$$

$$\Sigma_P^{-1} = \frac{1}{2,324 \times 10^{-5}} \begin{pmatrix} 0,01330 & 0,00435 \\ 0,00135 & 0,00143 \end{pmatrix} \simeq \begin{pmatrix} 572,3 & 188,4 \\ 58,2 & 61,8 \end{pmatrix}$$

Classificar $d_{12} = (y_1 = 0,37, y_2 = 0,84, y_3 = 1, y_4 = 1, y_5 = 0)$

$$y_{12} - \mu_P = \begin{bmatrix} 0,37 - 0,5562 \\ 0,84 - 0,45 \end{bmatrix} = \begin{bmatrix} -0,1862 \\ 0,39 \end{bmatrix}$$

$$(y_{12} - \mu_P)^T \Sigma_P^{-1} (y_{12} - \mu_P) \simeq 572,3 (-0,1862)^2 + 2 (188,4)(-0,1862) \times (0,39) + 61,8 (0,39)^2 \simeq 23,68$$

$$p(y_1, y_2 | P) = \frac{1}{2\pi \sqrt{2,324 \times 10^{-5}}} e^{-\frac{23,68}{2}} \simeq 2,37 \times 10^{-7}$$

$$p(P | x_2) = \frac{\frac{1}{2} \times (2,37 \times 10^{-4}) \times 1 \times \frac{2}{3}}{p(x_2)} \simeq \frac{7,9 \times 10^{-5}}{p(x_2)}$$

Classe M:

$$y_{12} - \mu_M = \begin{bmatrix} 0,37 - 0,4833 \\ 0,84 - 0,7267 \end{bmatrix} = \begin{bmatrix} -0,1133 \\ 0,1133 \end{bmatrix}$$

$$(y_{12} - \mu_N)^T \Sigma_N^{-1} (y_{12} - \mu_N) = 443,8 \cdot (-0,1133)^2 + 2(-63,3)(-0,1133) \cdot$$

$$\cdot (0,1133) + 233 (0,1833)^2 \cong 7,64$$

$$P(y_1, y_2 | N) = \frac{1}{2\pi \sqrt{1,526 \times 10^{-4}}} e^{\frac{-7,64}{2}} \cong 0,283$$

$$P(N | x_2) = \frac{\frac{1}{2} \times 0,283 \times \frac{2}{3} \times \frac{1}{3}}{p(x_7)} \cong \frac{0,0314}{p(x_7)}$$

Como $0,0314 > 7,9 \times 10^{-5}$, x_2 é classificado como M.

para $x_8 = [0,4; 0,6; 1; 0; 0]^t$:

Classe P:

Como $P(y_4 = 0, y_5 = 0 | P) = 0$ temos: $P(P | x_8) = \frac{\frac{1}{2} P(y_1, y_2 | P) \times 1 \times 0}{P(x_8)} = 0$

Classe N:

$$y_{12} - \mu_N = \begin{bmatrix} 0,4 - 0,4833 \\ 0,66 - 0,7267 \end{bmatrix} = \begin{bmatrix} -0,0833 \\ -0,0667 \end{bmatrix}$$

$$(y_{12} - \mu_N)^T \Sigma_N^{-1} (y_{12} - \mu_N) = 443,8 (-0,0833)^2 + 2(-63,3)(-0,0833)(-0,0667) +$$

$$+ 233 (-0,0667)^2 \cong 2,49$$

$$P(y_1, y_2 | N) = \frac{1}{2\pi \sqrt{1,526 \times 10^{-4}}} e^{\frac{-2,49}{2}} \cong 3,71$$

$$P(N | x_8) = \frac{\frac{1}{2} \times 3,71 \times \frac{2}{3} \times \frac{2}{3}}{p(x_8)} \cong \frac{0,824}{p(x_8)}$$ Como $0,824 > 0$ x_8 é classificado como N.

c) Assume Amenda independência condicional entre os grupos $\{x_1, x_2\}$ $\{x_3\}$ e $\{x_4, x_5\}$ reduz drasticamente o número de parâmetros a estimar (evitando estimar distribuições conjuntas sobre todas as combinações das variáveis). Isto atenua o problema de esparsidade de dados em amostras pequenas ($N=6$) reduzindo a variância da estimativa e melhorando a capacidade de generalização, embora possa introduzir viés se existirem dependências reais entre os grupos.

- Alternativa em b) com MAP: não haverá qualquer diferença. Como os priors das duas classes são iguais ($P(P) = P(M) = 0,5$) o termo $P(c)$ é uma constante igual em ambas as classes e cancela-se na comparação: $\arg\max_c P(c)\,p(x|c) = \arg\max_c p(x|c)$

Vantagem de MAP: Evita enviesar as palavras quando os priors observados no conjunto de treino não são representativos da população real (por exemplo, devido a amostragem desbalanceada) e dispensa a estimação de priors

② A distância de Hamming $dH(x_i, x_l) = \sum_{j=3}^{5} |x_{ij} - x_{lj}|$

	(x_3, x_4, x_5)	y_6	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8
x_1	(1,0,0)	N	0	2	2	0	1	1	1	0
x_2	(0,1,0)	N	2	0	2	2	1	1	1	2
x_3	(1,1,1)	P	2	2	0	2	1	1	1	2
x_4	(1,0,0)	N	0	2	2	0	1	1	1	0
x_5	(1,1,0)	P	1	1	1	1	0	0	0	1
x_6	(1,1,0)	P	1	1	1	1	0	0	0	1
x_2	(1,1,0)	P	1	1	1	1	0	0	0	1
x_8	(1,0,0)	N	0	2	2	0	1	1	1	0

• x_1 (vc Real = N)

• $dH=0$ {x_4(N)/x_8(N)} 2 vizinhos; $dH=1$ x_5((P), x_6(P), x_2(P) {3 vizinhos}

Para $k=3$ vai necessitar escolher entre os 3 empatados a $dH=1$.

Resolução para $k=1$ {x_4, x_8} → 2N, 0P → y_6 = N (correto)

• x_4 $dH=0$ = 2 vizinhos ; dH_1 = 3 vizinhos

Empate em $dH=1$ → usar $k=2$ {x_1, x_8} → 1N → y_6 = N (correto)

• x_8

$dH=0$ 2 vizinhos dH_1 3 vizinhos

• Empate em $dH=1$ → $k=2$ {x_1, x_4} → 2N → y_6 = N (correto)

CBE
ENGENHARIA E CONSTRUÇÃO
EM TELECOMUNICAÇÕES

~~x_1~~ x_2

$d_H=0$: $\emptyset$, $d_H=1$ 3 vizinhos

$\{x_5, x_6, x_7\} \rightarrow 3P, ON \Rightarrow \hat{y}_6 = P$ (incorrecte)

- x_3

$d_H=0$: $\emptyset$: $d_H=1 \rightarrow$ 3 vizinhos

$\{x_5, x_6, x_7\} \rightarrow 3P, ON \Rightarrow \hat{y}_6 = P$ (correcte)

- x_5

$d_H=0$: 2 vizinhos) $d_H=1$: 5 vizinhos

Empate em $d_H=1 \rightarrow$ usar-se $k=2$ $\{x_6, x_7\} \Rightarrow 2P \rightarrow \hat{y}_6 = P$ (correcte)

- x_6

$d_H=0$: 2 vizinhos) $d_H=1$: 5 vizinhos

Empate em $d_H=1 \rightarrow$ usar-se $k=2$ $\{x_5, x_7\} \rightarrow 2P \rightarrow \hat{y}_6 = P$ (correcte)

- x_7

$d_H=0$: 2 vizinhos $d_H=1$: 5 vizinhos.

Empate em $d_H=1 \rightarrow$ usar-se $k=2$: $\{x_5, x_6\} \rightarrow 2P \rightarrow \hat{y}_6 = P$ (correcte)

$$\text{Accuracy} = \frac{\text{corretos}}{\text{totais}} = \frac{7}{8} = 0{,}875 = 87{,}5\%$$

ii. A accuracy não deve sofrer qualquer alteração pois para variáveis binárias ($x_{ij} \in \{0,1\}$) a diferença absoluta entre coordenadas para pontos $x_i, x_l \in \{0,1\}$ pela qual $(x_{ij} - x_{lj})^2 = |x_{ij} - x_{lj}|$. Assim:

$$d_E(x_i, x_l) = \sqrt{\sum_{j=3}^{5} (x_{ij} - x_{lj})^2} = \sqrt{\sum_{j=3} x_{ij} - x_{lj}} = \sqrt{d_H(x_i, x_l)}$$

Como a função raiz quadrada é estritamente crescente em $]0, +\infty[$ preserva a ordem relativa de todas as distâncias e mantém os mesmos empates, vizinhanças e proximidades.

iii) Alteração com Chebyshev: Os resultados mudarão. Para dados binários, $d_\infty(x_i, x_l) = \max_j |x_{ij} - x_{lj}| \in \{0,1\}$: vale 0 se os dois vetores forem iguais e 1 se diferirem em 1 ou 3 atributos. Fixa a distância entre $d_H = 1, 2, 3$. Por exemplo para x_2 e x_3 (que não têm nenhum atributo 0), todos os restantes 7 observações passam a ter empate a $d_\infty = 1$, tornando impossível relevar um vizinho com apenas $k=3$ ou $k=5$ vizinhos sem desempate arbitrário.

Para qualquer ordem finita $p \geq 1$, como $|x_{ij} - x_{lj}|^p = |x_{ij} - x_{lj}|$, a distância de Minkowski reduz-se a $d_p(x_i, x_l) = (d_H(x_i, x_l))^{1/p}$.

Logo, qualquer $p \geq 1$ finito produz exatamente a mesma ordenação de vizinhos vista anteriormente especialmente $p=1$ (Hamming/Manhattan) por menor custo computacional (evita potências e raízes), e também a função $p \to \infty$ (Chebyshev) por pura desnecessidade.

CBE
ENGENHARIA E CONSTRUÇÃO
EM TELECOMUNICAÇÕES

6 Qst) Restringindo os neighbors obtidos apenas às observações de treino

para x_2 (1.1) (valor real $y_{1,2} = 0,32$)

Nas observações de treino, x_2 tem 2 vizinhos com $d_H = 0$, e 4 vizinhos com $d_H = 1$.

Usando $k=1$ com os vizinhos $\{x_5, x_6\}$ cujos valores de y_1 são

$y_{1,5} = 0,68$ e $y_{1,6} = 0,5$:

$$\hat{y}_{1,2} = \frac{y_{1,5} + y_{1,6}}{2} = \frac{0,68 + 0,5}{2} = 0,59$$

para x_3 (1,0,0) (valor real $y_{1,3} = 0,41$):

x_3 tem 2 vizinhos com $d_H = 0$ e 2 empates com $d_H = 1$: $\{x_5, x_6\}$

$\{x_1, x_4\}$

Y1 são $y_{1,1} = 0,54$ e $y_{1,4} = 0,42$

$$\hat{y}_{1,3} = \frac{y_{1,1} + y_{1,4}}{2} = \frac{0,54 + 0,42}{2} = 0,48$$

Erros de previsão $(y_i - \hat{y}_i)$

x_2: $|0,32 - 0,59| = 0,27 \rightarrow (0,32 - 0,59)^2 = 0,0784$

x_3: $|0,41 - 0,48| = 0,07 \rightarrow (0,41 - 0,48)^2 = 0,0049$

$$MAE: \frac{1}{2} \sum_{i \in \{2,3\}} |y_{1,i} - \hat{y}_{1,i}| = \frac{0,27 + 0,07}{2} = 0,17$$

$$RMSE = \sqrt{\frac{1}{2} \sum_{i \in \{2,3\}} (y_{1,i} - \hat{y}_{1,i})^2} = \sqrt{\frac{0,0784 + 0,0049}{2}} \approx 0,1656$$