Homework 8

Yuri Silva
e Rodrigo Baptista

① Para Y_1 temos 6 dados: A = 2, B = 1, C = 3

$P_A = \frac{1}{3}$ $P_B = \frac{1}{6}$ e $P_C = \frac{1}{2}$

$$H(S) = -\left(\frac{1}{3}\log_2\left(\frac{1}{3}\right) + \frac{1}{6}\log_2\left(\frac{1}{6}\right) + \frac{1}{2}\log_2\left(\frac{1}{2}\right)\right) = 1{,}4591 \text{ bits}$$

Atributos candidatos:

Y_1 → não pode pela regra

Y_2 → $H(S_{Y_2=0}) = -\left(2 \cdot \frac{2}{5}\log_2\left(\frac{2}{5}\right) + \frac{1}{5}\log_2\frac{1}{5}\right) = 1{,}0219$ bits

$H(S_{Y_2=1}) = 0$

$IG(S, Y_2) =$ [illegible] $1{,}4591 - \frac{5}{6} \cdot 1{,}5219 = 0{,}1908$ bits

Y_3 → $H(S_{Y_3=0}) = -\left(\frac{1}{3}\log_2\frac{1}{3} + \frac{2}{3}\log_2\frac{2}{3}\right) = 0{,}9183$ bits

$H(S_{Y_3=1}) = \left(-2 \cdot \frac{1}{2}\log_2\frac{1}{2}\right) = 1$ bit

$H(S_{Y_3=2}) = 0$

$IG(S, Y_3) = 1{,}4591 - \frac{3}{6}(0{,}9183) + \frac{2}{6}(1) + \frac{1}{6}(0) = 0{,}6666$ bits

Y_4 → $H(S_{Y_4=0}) = 1$ bit

$H(S_{Y_4=1}) = 0$

$H(S_{Y_4=2}) = \log_2(3) = 1{,}585$ bits

$IG(S, Y_4) = 1{,}4591 - \frac{2}{6}(1) + \frac{1}{6}(0) + \frac{3}{6}(1{,}5850) = 0{,}3731$ bits

Como $IG(S, Y_3) > IG(S, Y_4) > IG(S, Y_2)$ então Y_3 é o escolhido para o nó.

Se $Y_3 = 0$ há um divisão por chegar a 3 observações com as variáveis X_2 e X_4

Se $Y_1 \rightarrow$ todos são 0 logo $IG = 0$

$Y_4 \rightarrow H(S_{Y_4=0}) = 1$ bit

$H(S_{Y_4=1}) = 0$

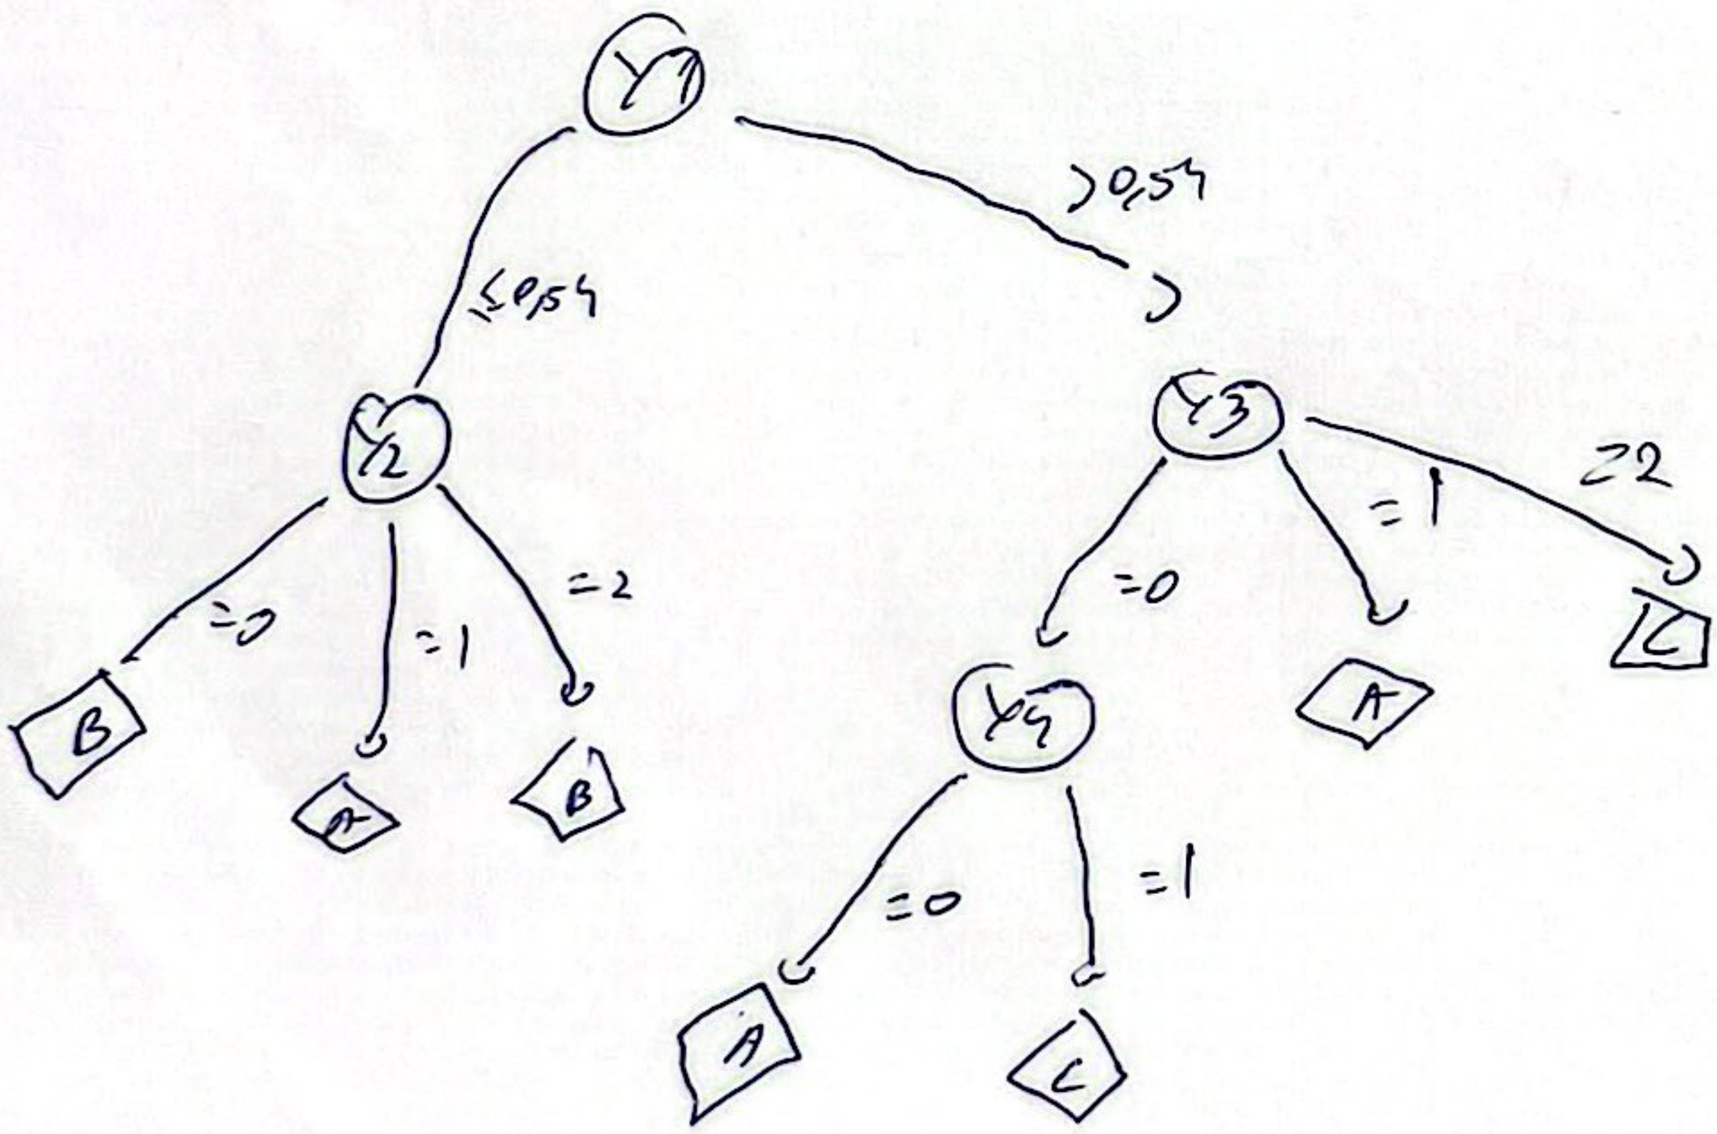
$IG > 0$ logo $IG(Y_4) > IG(Y_2)$ então Y_4 é o relevando para nó

para $Y_4 = 0$ existe A e C por ordem alfabética ganha o A

para $Y_4 = 1$ é C

$Y_3 = 1$ existem A e B por ordem alfabética ganha o A

$Y_3 = 2$ é C



(2)

	Real	Previsto
x_1	B	B
x_2	A	A
x_3	B	B
x_4	A	B
x_5	B	B
x_6	B	B
x_7	C	A
x_8	C	C
x_9	A	A
x_{10}	B	A
x_{11}	A	A
x_{12}	C	C

Matriz de confusão

Real \ ~~Previsto~~ Previsto	A	B	C	Total
A	3	1	0	4
B	1	4	0	5
C	1	0	2	3
Total	5	5	2	12

(3) Na selénium de espuma em 6 observações comete 1 erro (x_4).

Se o pé x for substituído por uma folha real por B por ser a classe maioritária. Assim em 6 observações real cometido dois erros (x_2 e x_4) mais um erro

como o resto da árvore mantém intacta é cometido 1 erro em 12 observações

$\frac{1}{12} = 8{,}33\%$. < 10% de erro. Logo a substituição em X pode ser substituída por uma folha com classe B